학 사 학 위 논 문

커리큘럼 언러닝:
머신 언러닝을 위한 기억점수 기반 커리큘럼 설계
Curriculum Unlearning:
Memorization Score Based Curriculum Design for Machine Unlearning

충남대학교

공과대학 컴퓨터융합학부

202202597 배 주 하
202202598 백 정 은
202202651 최 효 은

지도교수 양 희 철

2026년 2월

커리큘럼 언러닝:
머신 언러닝을 위한 기억점수 기반 커리큘럼 설계
Curriculum Unlearning:
Memorization Score Based Curriculum Design for Machine Unlearning

지도교수 양 희 철

이 논문을 공학사학위
청구논문으로 제출함

2025년 12월

충 남 대 학 교

공과대학 컴퓨터융합학부

202202597 배 주 하
202202598 백 정 은
202202651 최 효 은

목차

Ⅰ. 서론 ····· 5
1. 연구 배경 ····· 5
2.. 연구의 필요성 및 문제 제기 ····· 5
3. 연구 목적 ····· 6
4. 연구의 기여 ····· 6
5. 논문의 구성 ····· 7
Ⅱ. 문헌 연구 ····· 8
1. 머신 언러닝 (Machine Unlearning) ····· 8
1) 정확한 언러닝 (Exact Unlearning) ····· 8
2) 근사적 언러닝 (Approximate Unlearning) ····· 8
2. 기억 점수 (Memorization Score) ····· 9
3. 커리큘럼 학습과 언러닝의 통합 ····· 9
Ⅲ 제안 방법 ····· 11
····· 11
1. 커리큘럼 언러닝 프레임워크 개요 ····· 11
[그림 1] 제안하는 커리큘럼 언러닝 프레임워크 ····· 11
2. 기억 점수 산출 ····· 11
3. 커리큘럼 구성 ····· 12
4. 순차 언러닝 (Sequential Unlearning) ····· 12
Ⅳ 실험 설계 및 구현 ····· 14
1. 실험 환경 ····· 14
2. 데이터셋 및 전처리 파이프라인 ····· 14
1) 데이터셋 구성 ····· 14

2) 데이터 전처리 및 증강 ····· 14
3. 타겟 모델 및 학습 전략 ····· 15
1) 모델 아키텍처 ····· 15
2) 초기 모델 학습 ····· 15
4. 제안 프레임워크 구현 상세 ····· 16
1) 난이도 점수 산출 ····· 16
2) 데이터 정렬 및 분할 ····· 16
3) 불균형 해소를 위한 업샘플링(Upsampling) ····· 17
5. 언러닝 시나리오 정의 ····· 17
6. 비교 알고리즘 구현 및 하이퍼파라미터 ····· 17
1) Fine-tuning (FT) ····· 17
2) NegGrad (Negative Gradient) ····· 18
3) SCRUB ····· 18
Ⅴ 실험 결과 및 분석 ····· 19
1. 실험 개요 및 평가지표 ····· 19
[표 1] 알고리즘 및 커리큘럼 방향에 따른 언러닝 성능 비교 (Forget Accuracy / Retain Accuracy / Test Accuracy, %) ····· 19
2. 시나리오별 심층 분석 ····· 19
1) Class Forgetting (특정 클래스 망각) ····· 20
2) Random Class Forgetting (무작위 클래스 망각) ····· 20
3) Random Forgetting (무작위 샘플 망각) ····· 21
3. 알고리즘 메커니즘에 따른 최적 커리큘럼 분석 ····· 21
1) 손실 최대화 기반 기법 (NegGrad, SCRUB) → Low-first 전략 ····· 21
2) 지식 보존 기반 기법 (Fine-tuning) → High-first 전략 ····· 22
4. 망각과 보존의 트레이드오프 (Trade-off) ····· 22
Ⅵ 한계점 및 향후 연구 방향 ····· 23
1. 연구의 한계점 ····· 23

1) 기억 점수 산출의 연산 비용 및 근사 오차 ····· 23
2) 정적 커리큘럼(Static Curriculum) ····· 23
3) 실험 환경의 제한적 범위 ····· 23
2. 향후 연구 방향 ····· 24
1) 적응형 커리큘럼 언러닝 (Adaptive Curriculum Unlearning) ····· 24
2) 경량화된 난이도 측정 지표 개발 ····· 24
3) 생성형 모델 및 다양한 도메인으로의 확장 ····· 24
4) 이론적 분석 및 최적화 경로 규명 ····· 25
참고문헌 ····· 26

표목차

표 1 알고리즘 및 커리큘럼 방향에 따른 언러닝 성능 비교 (Forget Accuracy / Retain Accuracy / Test Accuracy, %) ····· 19

그림목차

그림 1 제안하는 커리큘럼 언러닝 프레임워크 ····· 11

Ⅰ. 서론

1. 연구 배경

최근 인공지능(Artificial Intelligence) 기술의 비약적인 발전으로 이미지 분류, 자연어 처리 등 다양한 분야에서 인간의 능력을 상회하는 성능을 보여주고 있다. 그러나 이러한 모델의 성능 향상은 대규모 데이터셋을 기반으로 이루어지며, 이 과정에서 개인정보, 금융 정보, 의료 기록 등 민감한 정보가 모델 내부에 암기(Memorization)되는 문제가 발생한다.

이러한 개인정보 침해 우려에 대응하여 유럽 연합(EU)의 일반개인정보보호법(GDPR)은 정보 주체의 '잊힐 권리(Right to be Forgotten)'를 법적으로 보장하고 있다. 이는 데이터베이스에서의 단순 삭제를 넘어, 해당 데이터를 학습한 인공지능 모델에서도 그 영향력을 완전히 제거할 것을 요구한다. 만약 삭제된 데이터의 정보가 모델의 파라미터(Weight)에 잔존할 경우, 멤버십 추론 공격(Membership Inference Attack) 등을 통해 개인정보가 유출될 위험이 있으며, 잘못된 정보나 편향된 데이터가 모델의 의사결정에 지속적인 악영향을 미칠 수 있다.

따라서 이미 학습이 완료된 모델에서 특정 데이터의 정보를 선택적으로 제거하여, 마치 해당 데이터를 처음부터 학습하지 않은 것과 같은 상태를 만드는 머신 언러닝(Machine Unlearning) 기술이 필수적인 연구 분야로 대두되고 있다.

2.. 연구의 필요성 및 문제 제기

머신 언러닝을 수행하는 가장 이상적이고 확실한 방법은 삭제 요청이 들어온 데이터(Forget Set)를 제외하고, 나머지 데이터(Retain Set)만으로 모델을 초기화하여 다시 학습하는 '재학습(Retraining)'이다. 하지만 최신 딥러닝 모델은 수백만 개 이상의 파라미터와 방대한 학습 데이터를 필요로 하므로, 매번 재학습을 수행하는 것은 막대한 시간과 계산 자원을 소모하여 현실적으로 적용하기 어렵다.

이러한 한계를 극복하기 위해, 재학습을 수행하지 않고 모델 파라미터를 효율적으로 수정하여 망각 효과를 근사(Approximate)하는 다양한 기법들이 제안되었다. 대표적으로 모델 파라미터를 미세 조정(Fine-tuning)하거나, 삭제할 데이터에 대해 손실 함수를 역으로 최적화하는 기법(Gradient Ascent), 혹은 학생-교사(Student-Teacher) 프레임워크를 활용하는 기법 등이 있다.

그러나 기존의 근사 언러닝 연구들은 대부분 데이터셋을 '순서가 없는 단순한 집합'으로 간주한다는 한계가 있다. 이는 데이터가 모델에 미치는 영향이 모두 동일하다고 가정하고 일괄적인 처리를 수행하는 방식이다. 하지만 인간의 학습 과정에서 쉬운 개념부터 어려운 개념으로 순차적으로 학습하는 것이 효율적인 것처럼, 망각 과정에서도 데이터의 특성에 따라 처리 순서가 결과에 중요한 영향을 미칠 수 있다. 특히, 모델이 강하게 암기하고 있는 데이터와 그렇지 않은 데이터를 동일한 순서와 강도로 처리할 경우, 삭제 대상이 아닌 데이터(Retain Set)에 대한 지식까지 손상되는 '치명적 망각(Catastrophic Forgetting)' 현상이 발생하거나, 망각 성능이 저하되는 문제가 발생할 수 있다.

3. 연구 목적

본 연구는 "데이터의 처리 순서가 머신 언러닝의 성능과 안정성에 영향을 미친다"는 가설을 바탕으로, 커리큘럼 학습(Curriculum Learning)의 개념을 언러닝 과정에 도입하는 것을 목적으로 한다.

커리큘럼 학습은 학습 데이터를 난이도 순으로 정렬하여 모델이 점진적으로 학습하도록 유도하여 수렴 속도와 일반화 성능을 높이는 기법이다. 본 연구에서는 이를 역으로 적용하여, 데이터별 '망각 난이도'를 정의하고 이에 따른 최적의 삭제 순서를 제안한다. 구체적인 연구 목표는 다음과 같다.

데이터 난이도 정량화: Feldman 등이 제안한 기억 점수(Memorization Score)를 활용하여, 각 데이터 샘플이 모델에 얼마나 강하게 암기되었는지를 정량적으로 측정한다.

커리큘럼 프레임워크 설계: 측정된 기억 점수를 기반으로 데이터를 'Low-first' 및 'High-first' 순서로 정렬하여 순차적으로 언러닝을 수행하는 프레임워크를 설계한다.

알고리즘별 분석: Fine-tuning(FT), Negative Gradient(NegGrad), SCRUB 등 서로 다른 메커니즘을 가진 언러닝 알고리즘들이 데이터 처리 순서에 따라 어떠한 성능 변화를 보이는지 실험적으로 검증하고, 각 알고리즘에 최적화된 커리큘럼 전략을 도출한다.

4. 연구의 기여

본 연구를 통해 도출된 주요 기여점은 다음과 같다.

첫째, 확장된 커리큘럼 언러닝 프레임워크 제안: 기존 언러닝 연구들이 간과했던 '데이터 처리 순서'의 중요성을 부각하고, 삭제 대상(Forget Set)뿐만 아니라 유지 대상(Retain Set)의 학습 순서까지 고려하는 통합된 프레임워크를 제안하였다.

둘째, 언러닝 알고리즘과 데이터 순서 간의 상관관계 규명: 실험을 통해 모든 상황에 만능인 단일 커리큘럼은 존재하지 않으며, 언러닝 알고리즘이 주로 활용하는 데이터의 종류(Retain Set 중심 vs. Forget Set 중심)에 따라 최적의 커리큘럼 방향이 달라짐을 입증하였다. 예를 들어, Retain Set을 주로 사용하는 FT 기법은 'High-first' 전략이, Forget

Set을 공격적으로 활용하는 NegGrad 기법은 'Low-first' 전략이 효과적임을 밝혔다.

셋째, 실증적 성능 검증: CIFAR-10 데이터셋과 ResNet-18 모델을 활용한 다양한 망각 시나리오(Class Forgetting, Random Forgetting 등)에서 제안하는 커리큘럼을 적용했을 때, 기존 무작위(Random) 방식 대비 언러닝 정확도와 모델 유지 성능(Retain Accuracy) 간의 균형(Trade-off)이 개선됨을 확인하였다.

5. 논문의 구성

본 논문의 구성은 다음과 같다. 제 2장에서는 머신 언러닝의 주요 기법들과 커리큘럼 학습, 그리고 기억 점수에 대한 관련 연구를 고찰한다. 제 3장에서는 본 연구에서 제안하는 기억 점수 기반의 커리큘럼 언러닝 프레임워크의 구조와 상세 알고리즘을 기술한다. 제 4장에서는 제안하는 기법의 유효성을 검증하기 위한 실험 환경, 데이터셋, 비교 대상 알고리즘 및 평가지표를 설명하고, 제 5장에서는 실험 결과를 통해 커리큘럼 전략에 따른 성능 변화를 정량적, 정성적으로 분석한다. 마지막으로 제 6장에서는 결론을 맺고 본 연구의 한계점 및 향후 연구 방향을 제시한다.

Ⅱ. 문헌 연구

1. 머신 언러닝 (Machine Unlearning)

머신 언러닝 기술은 삭제 요구에 대한 이행 수준과 접근 방식에 따라 크게 정확한 언러닝(Exact Unlearning)과 근사적 언러닝(Approximate Unlearning)으로 구분된다.

1) 정확한 언러닝 (Exact Unlearning)

정확한 언러닝은 삭제 대상 데이터(Forget Set)를 완전히 배제하고 모델을 처음부터 다시 학습(Retraining)하여, 해당 데이터의 영향이 수학적으로 완전히 제거된 모델을 얻는 것을 목표로 한다. 이는 이론적으로 가장 완벽한 해결책이나, 대규모 딥러닝 모델의 경우 전체 데이터를 재학습하는 데 막대한 시간과 계산 자원이 소요되므로 현실적인 제약이 크다. 이를 보완하기 위해 Bourtoule 등은 SISA(Sharded, Isolated, Sliced, and Aggregated) 프레임워크를 제안하였다. SISA는 전체 훈련 데이터를 다수의 파편(Shard)으로 분할하여 독립적인 모델을 학습시키고 추론 시 이를 병합하는 방식이다. 특정 데이터 삭제 요청 시 해당 데이터가 포함된 파편의 모델만 재학습하면 되므로 효율성을 높일 수 있다. 그러나 파편의 수가 늘어날수록 앙상블 모델의 전체적인 예측 성능이 저하될 수 있으며, 데이터 분할 전략에 따라 성능 편차가 발생한다는 한계가 있다.

2) 근사적 언러닝 (Approximate Unlearning)

근사적 언러닝은 모델 파라미터를 부분적으로 업데이트하여 삭제 대상 데이터의 영향을 제거하거나 최소화하는 기법들을 통칭한다. 완전 재학습에 비해 월등한 효율성을 가지며, 다음과 같은 다양한 기법들이 연구되고 있다.

파인 튜닝(Fine-tuning, FT): 가장 직관적인 방법으로, 삭제 대상 데이터를 제외한 잔여 데이터(Retain Set)만을 사용하여 모델을 추가 학습(Fine-tuning)하는 방식이다. 구현이 용이하고 범용적인 베이스라인으로 활용되지만, 일괄적인 파인 튜닝 과정에서 잔여 데이터에 대한 과적합이나 치명적 망각(Catastrophic Forgetting)이 발생하여 모델의 일반화 성능이 저하될 위험이 있다.

손실 역최적화(Gradient Ascent): Golatkar 등은 삭제할 데이터에 대한 손실 함수를 최대화하는 방향으로 파라미터를 업데이트하는 NegGrad 기법을 제안하였다. 이는 모델이 삭제 데이터를 더 이상 예측하지 못하도록 강제하여 빠르게 기억을 지울 수 있으나, 모델의 가중치를 급격하게 변화시켜 잔여 데이터에 대한 성능(Retain Accuracy)까지 크게 훼

손시키는 부작용이 보고되었다.

이중 목적 최적화 및 SCRUB: NegGrad의 한계를 극복하기 위해 제안된 NegGrad+는 잔여 데이터의 손실은 최소화하고 삭제 데이터의 손실은 최대화하는 이중 목적 함수를 사용한다. Kurmanji 등은 이를 확장하여 교사-학생(Teacher-Student) 프레임워크 기반의 SCRUB 알고리즘을 제안하였다. SCRUB은 학생 모델이 잔여 데이터에 대해서는 교사 모델(원본 모델)의 지식을 모방하고, 삭제 데이터에 대해서는 교사와 다른 예측을 하도록 유도한다. 이 기법은 현재 안정적인 망각 성능과 높은 모델 유지 성능을 동시에 달성하는 최신 기법으로 평가받고 있다.

이 외에도 모델 가중치에 L1 정규화를 적용하거나, 영향 함수(Influence Function)를 통해 삭제 데이터와 연관된 가중치만 선별적으로 수정하는 연구, 삭제 데이터의 라벨을 무작위로 재할당(Relabeling)하는 연구 등이 진행되고 있다.

2. 기억 점수 (Memorization Score)

모든 데이터가 모델 학습에 동일한 기여를 하는 것은 아니다. Feldman 등은 머신러닝 모델이 특정 데이터를 얼마나 '암기(Memorize)'해야 성능을 낼 수 있는지를 정량화하기 위해 기억 점수(Memorization Score) 개념을 제시하였다.

$$mem(A,D,i) = \Pr_{f \sim A(D)}[f(x_i) = y_i] - \Pr_{f \sim A(D \setminus i)}[f(x_i) = y_i]$$

이 점수는 특정 샘플이 학습 데이터에 포함되었을 때와 제외되었을 때, 모델이 해당 샘플을 올바르게 예측할 확률의 차이로 정의되며, 값이 높을수록 모델이 그 샘플을 직접 암기했음을, 낮을수록 다른 데이터로부터 일반화되어 쉽게 잊히는 데이터를 의미한다.

기억 점수가 높은 데이터는 주로 데이터 분포의 꼬리에 위치한 특이값(Outlier)이나 노이즈가 섞인 데이터로, 모델이 이를 맞추기 위해서는 일반화가 아닌 암기가 필요함을 의미한다. 반대로 기억 점수가 낮은 데이터는 다른 데이터들로부터 쉽게 유추 가능한 전형적인 패턴을 가진다.

기억 점수의 정확한 계산을 위해서는 수천 번의 재학습이 필요하여 현실적으로 불가능하므로, 많은 근사 지표들이 연구되었다. Toneva 등은 학습 중 예측이 정답에서 오답으로 바뀌는 '망각 이벤트(Forgetting Events)' 횟수로 난이도를 측정하였으며, 최근에는 모델의 예측 신뢰도(Confidence)나 분산 등을 활용한 C-Proxy 등의 지표가 제안되어 기억 점수를 효율적으로 추정하는 데 활용되고 있다.

3. 커리큘럼 학습과 언러닝의 통합

커리큘럼 학습(Curriculum Learning)은 인간이 쉬운 개념부터 단계적으로 학습하는 과정에서 착안하여, Bengio 등이 제안한 학습 전략이다. 이는 학습 데이터의 순서를 난이도 기반으로 재정렬(Scheduling)하여 모델의 수렴 속도를 높이고 국소 최적해(Local Minima) 문제를 완화하는 데 효과적임이 입증되었다.
최근에는 이러한 커리큘럼의 개념을 역으로 적용하여 머신 언러닝의 효율성을 높이려는 시도가 이어지고 있다. 무작위 순서로 데이터를 삭제하는 기존 방식과 달리, 데이터의 망각 난이도에 따라 삭제 순서를 조정함으로써 모델의 안정성을 확보하려는 것이다.
Zhao 등은 삭제할 데이터를 기억 점수에 따라 '쉬운', '중간', '어려운' 그룹으로 나누고 이를 순차적으로 언러닝하는 프레임워크를 제안하였다. 실험 결과, 순차적 언러닝이 일괄 삭제보다 잔여 성능 유지에 효과적임을 보였다.

CUFG (Curriculum Unlearning with Gradient): Miao 등은 '쉬운 데이터부터 어려운 데이터 순(Easy-to-Hard)'으로 삭제하는 커리큘럼 전략이 모델 붕괴(Model Collapse)를 방지하고 재학습에 가까운 성능을 낼 수 있음을 확인하였다.
이러한 선행 연구들은 데이터의 처리 순서가 언러닝 성능에 유의미한 영향을 미침을 시사한다. 하지만 기존 연구들은 주로 특정 알고리즘(예: Fine-tuning)에 국한되거나 삭제 대상(Forget Set)의 순서만을 고려하는 경향이 있었다. 본 연구는 이를 확장하여 다양한 언러닝 알고리즘에 대해 Forget Set 뿐만 아니라 Retain Set의 학습 순서까지 포괄하는 통합된 커리큘럼 프레임워크를 제안하고 분석하고자 한다.

Ⅲ 제안 방법

1. 커리큘럼 언러닝 프레임워크 개요

본 장에서는 머신 언러닝의 안정성과 효율성을 극대화하기 위해 커리큘럼 학습(Curriculum Learning)의 개념을 접목한 기억 점수 기반 커리큘럼 언러닝(Memorization Score-based Curriculum Unlearning) 프레임워크를 제안한다.

기존의 근사적 언러닝 기법들은 삭제 대상 데이터(Forget Set)를 단일한 집합으로 간주하여 일괄적으로 처리하였다. 이는 데이터 개별의 특성이나 모델에 미치는 영향력을 고려하지 않은 접근으로, 과도한 망각(Over-forgetting)이나 잔여 데이터에 대한 성능 저하를 초래할 수 있다. 이에 본 연구는 각 데이터가 모델 학습에 기여하는 정도, 즉 '망각 난이도'를 정량화하고, 이를 기반으로 최적의 삭제 순서를 결정하는 체계적인 접근법을 제시한다.

제안하는 프레임워크는 [그림 1]과 같이 크게 세 단계로 구성된다.

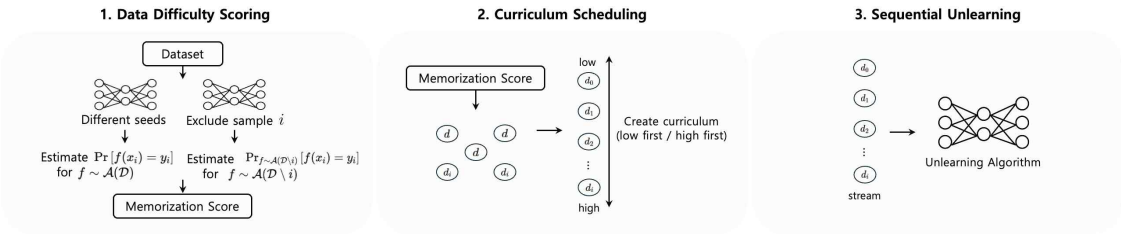

[그림 1] 제안하는 커리큘럼 언러닝 프레임워크

데이터 난이도 채점 단계 (Data Difficulty Scoring): 기억 점수를 활용해 각 데이터 샘플의 '망각 난이도'를 정량화한다.
커리큘럼 구성 단계 (Curriculum Scheduling): 산출된 점수를 바탕으로 삭제할 데이터의 순서(Low-first, High-first 등)를 결정한다.
순차 언러닝 단계 (Sequential Unlearning): 결정된 커리큘럼에 따라 데이터를 분할하여 단계적으로 모델 업데이트를 수행한다.

이 프레임워크는 모듈식 설계를 채택하여 기억 점수 지표, 커리큘럼 전략, 그리고 기저 언러닝 알고리즘을 독립적으로 조합할 수 있는 유연성을 갖는다.

2. 기억 점수 산출

첫 번째 단계에서는 전체 훈련 데이터 D_total로 학습된 초기 모델 M_O에 대하여, 삭

제 대상 데이터 집합 $D_{forget} \subset D_{total}$에 속한 각 샘플 d의 기억 점수(Memorization Score)를 산출한다.

Feldman 등이 정의한 이론적 기억 점수는 특정 데이터의 포함 여부에 따른 모델 성능 차이를 계산해야 하므로, 수천 번의 재학습이 요구되어 계산 비용이 매우 높다. 따라서 본 연구에서는 학습 과정에서 관찰되는 학습 곡선(Learning Curve)과 망각 이벤트(Forgetting Events)를 활용한 근사적 추정 방식을 채택하였다.

구체적으로, 각 데이터 d의 손실값 L(d)와 예측 확률 $p(y_d \mid x_d)$, 그리고 학습 도중 예측 결과가 정답에서 오답으로 번복된 횟수를 종합하여 점수를 매긴다.

Low Score (쉬운 데이터): 최종 모델이 높은 신뢰도(Confidence)로 정답을 예측하며, 학습 과정에서 예측 번복이 거의 없는 데이터. 이는 모델이 일반화된 패턴으로 학습한 데이터로 간주된다.

High Score (어려운 데이터): 최종 모델의 예측 신뢰도가 낮거나, 학습 도중 빈번하게 예측이 뒤바뀐 데이터. 이는 모델이 일반화하기 어려워 파라미터에 강하게 암기(Memorize)된 데이터로 판단한다.

3. 커리큘럼 구성

산출된 기억 점수를 기준으로 삭제 대상 데이터 D_{forget}를 정렬하여 커리큘럼을 구성한다. 본 연구에서는 다음과 같은 세 가지 주요 커리큘럼 전략을 제안하고 비교한다.

Low-first: 기억 점수가 낮은(쉬운) 데이터부터 우선적으로 삭제하고, 점차 점수가 높은(어려운) 데이터로 진행하는 전략이다. 초기에 모델에 큰 충격을 주지 않고 서서히 망각을 유도하여, 잔여 데이터(Retain Set)에 대한 성능 저하를 최소화하고 안정적인 언러닝을 달성하는 것을 목표로 한다.

High-first: 기억 점수가 높은(어려운) 데이터, 즉 모델이 강하게 암기한 데이터를 먼저 삭제하는 전략이다. 모델에 영향력이 큰 데이터를 초기에 제거함으로써 빠른 망각 효과를 기대할 수 있으나, 급격한 파라미터 변화로 인해 초기 성능 저하가 발생할 위험이 있다.

Random (Baseline): 기억 점수와 무관하게 삭제 대상 데이터를 무작위 순서로 정렬하여 제거하는 전략이다. 이는 커리큘럼 효과를 검증하기 위한 비교군(Baseline)으로 사용된다.

4. 순차 언러닝 (Sequential Unlearning)

마지막 단계에서는 구성된 커리큘럼에 따라 순차적인 언러닝을 수행한다. 초기 모델 f_0에서 시작하여, 각 단계 k ($1 \le k \le M$)마다 해당 단계의 삭제 데이터 S_k를 망각하도록 모델을 업데이트하여 f_k를 생성한다.

$$f_k = \mathrm{Unlearn}\left(f_{k-1},\ S_k,\ D \setminus \bigcup_{i=1}^{k} S_i\right)$$

이 과정에서 적용 가능한 대표적인 기저 알고리즘은 다음과 같다.
Fine-tuning (FT): f_(k-1)을 잔여 데이터 D \ S_k로 추가 학습(Fine-tuning)하여 S_k의 정보를 희석시킨다.
NegGrad (Negative Gradient): S_k에 대해 손실 함수를 최대화하는 방향(Gradient Ascent)으로 f_(k-1)을 업데이트한다.
SCRUB: 교사-학생 프레임워크를 활용하여, S_k에 대해서는 예측을 불일치시키고 잔여 데이터에 대해서는 일치시키도록 최적화한다.

이 과정을 M 단계까지 반복하면, 최종적으로 삭제 대상 전체 S가 제거된 모델 f_M을 얻게 된다. 순차적 접근은 일괄 삭제(One-shot Unlearning)에 비해 연산 비용이 증가하지만, 각 단계별로 모델의 변화폭을 제어할 수 있어 성능 유지와 완전한 망각 사이의 균형을 맞추는 데 유리하다.

Ⅳ 실험 설계 및 구현

1. 실험 환경

본 연구의 모든 실험은 대규모 연산과 반복적인 모델 재학습(Retraining) 시뮬레이션을 수행하기 다음과 같은 고성능 컴퓨팅 환경에서 진행되었다. 딥러닝 프레임워크로는 PyTorch를 사용하였으며, 데이터 전처리 및 수치 연산을 위해 Torchvision과 NumPy 라이브러리를 활용하였다. 실험의 재현성을 보장하기 위해, 데이터 셔플링, 모델 파라미터 초기화, 그리고 데이터셋 분할 과정에 관여하는 모든 난수 생성기(Random Number Generator)의 시드(Seed)는 42로 고정하였다. 상세한 시스템 사양은 다음과 같다.

Operating System: Ubuntu 20.04 LTS
Language: Python 3.8.10
Deep Learning Framework: PyTorch 1.13.1, Torchvision 0.14.1
Libraries: NumPy 1.21, SciPy 1.7

2. 데이터셋 및 전처리 파이프라인

1) 데이터셋 구성

실험에는 이미지 분류 모델의 망각 성능을 평가하기 위한 표준 벤치마크로 CIFAR-10 데이터셋을 채택하였다. 이 데이터셋은 10개의 클래스(Airplane, Automobile, Bird, Cat, Deer, Dog, Frog, Horse, Ship, Truck)로 구성된 60,000장의 32×32 컬러 이미지로 이루어져 있으며, 50,000장은 모델 학습(Training)에, 10,000장은 성능 평가(Testing)에 사용된다.

2) 데이터 전처리 및 증강

모델의 일반화 성능을 확보하고 과적합(Overfitting)을 방지하기 위해, 학습 단계에서 다음과 같은 데이터 증강(Data Augmentation) 및 정규화(Normalization) 파이프라인을 구축하였다.

Random Crop: 원본 이미지의 가장자리에 4픽셀의 패딩(Padding)을 추가한 후, 32×32 크기로 무작위 자르기를 수행하여 위치 불변성(Translation Invariance)을 학습하도록 유도한다.

Random Horizontal Flip: 50%의 확률로 이미지를 좌우 반전시킨다.

Normalization: 이미지의 각 RGB 채널에 대해 CIFAR-10 데이터셋의 평균과 표준편차를 적용하여 정규화한다.

평가(Evaluation) 및 언러닝 성능 측정 시에는 데이터 증강을 비활성화하고 정규화만 적용하여, 일관된 조건에서 결정론적(Deterministic)인 성능을 측정하였다.

3. 타겟 모델 및 학습 전략

1) 모델 아키텍처

언러닝의 대상이 되는 원본 모델(Original Model)로는 ResNet-18 아키텍처를 사용하였다. ResNet-18은 잔차 연결(Residual Connection)을 포함한 18개의 깊은 계층을 가지며, 약 1,100만 개의 파라미터를 보유하여 CIFAR-10 데이터의 특징을 학습하고 암기(Memorization)하기에 충분한 용량을 가진다.

2) 초기 모델 학습

언러닝을 수행하기 전, 전체 데이터셋 D_total에 대해 모델을 충분히 학습시켜 베이스라인을 구축하였다. 학습에 사용된 하이퍼파라미터는 다음과 같이 설정되었다.

Optimizer: SGD (Stochastic Gradient Descent)

Momentum: 0.9

Weight Decay: $5\times10-4$ (L2 Regularization)
Batch Size: 128

Learning Rate: 초기값 0.1에서 시작하여, 250 Epoch 동안 Cosine Annealing 스케줄러를 통해 0에 가깝게 감소시킨다.

Total Epochs: 250

위 설정으로 학습된 초기 모델은 테스트 셋에 대해 약 93% 내외의 정확도(Accuracy)를

달성하였으며, 이를 모든 언러닝 실험의 시작점(Start Point)으로 사용하였다.

4. 제안 프레임워크 구현 상세

본 연구의 핵심인 기억 점수 기반 커리큘럼 언러닝의 전체 프로세스는

(1) 난이도 점수 산출,
(2) 커리큘럼 기반 데이터 분할,
(3) 업샘플링 및 로더 구성의 단계로 진행된다.

1) 난이도 점수 산출

각 데이터 샘플 x_i의 망각 난이도를 정량화하기 위해 다음 세 가지 스코어링 메커니즘을 구현하였다.

Memorization Score (Feldman): 사전 계산된 각 샘플의 인덱스에 매핑되는 점수를 로드한다. 이는 모델 학습 시 해당 샘플의 포함 여부에 따른 예측 확률 변화량을 나타낸다.

Entanglement Score (ES): 사전 학습된 모델의 특성 추출기(Feature Extractor)가 생성한 임베딩 공간에서의 거리(Distance)를 기반으로 한다. 전체 훈련 데이터의 평균 임베딩 벡터 μ를 계산하고, 각 샘플의 임베딩 e_i와의 유클리드 거리 제곱 $S_{ES} = \| e_i - \mu \|^2$ 을 점수로 사용한다. 이는 분포의 중심에서 멀리 떨어진 특이치(Outlier)일수록 높은 점수를 부여한다.

Confidence Proxy (C-Proxy): 모델의 Cross-Entropy Loss 값을 점수로 활용한다. $S_{CP} = -\log(P(y_i \mid x_i))$. 손실값이 클수록 모델이 예측에 확신을 갖지 못하는 '어려운 데이터'로 간주한다.

2) 데이터 정렬 및 분할

산출된 점수를 바탕으로 삭제 대상 데이터(Forget Set) D_{forget}를 정렬하고, M개의 단계로 분할한다.

Low-first Strategy: 점수의 오름차순(Ascending)으로 정렬하여, S_1에 가장 점수가 낮은(쉬운) 데이터가 배치되도록 한다.

High-first Strategy: 점수의 내림차순(Descending)으로 정렬하여, S_1에 가장 점수가 높은(어려운) 데이터가 배치되도록 한다.

3) 불균형 해소를 위한 업샘플링(Upsampling)

커리큘럼 언러닝 수행 시, 삭제 대상 데이터(Forget Set)의 크기는 잔여 데이터(Retain Set)에 비해 현저히 작다 (예: 5,000 vs 45,000). 이를 1:1로 매칭하여 학습할 경우 배치 구성의 불균형이 발생한다. 이를 해결하기 위해 Forget Set의 인덱스 배열을 반복 복제(Repeat)하여 Retain Set의 크기에 맞게 길이를 확장한다. 예를 들어 Forget Set이 [1,2]이고 Retain Set의 크기가 5라면, 업샘플링된 결과는 [1,1,1,2,2]와 같이 생성된다. 이를 통해 매 Epoch마다 모든 Retain 데이터가 학습될 때 Forget 데이터도 균등한 빈도로 커리큘럼에 반영되도록 설계하였다.

5. 언러닝 시나리오 정의

Class Forgetting: class는 0 (Airplane)으로 설정. 해당 클래스 라벨을 가진 모든 인덱스를 추출하여 Forget Set으로 정의한다.
Random Forgetting: 전체 훈련 인덱스 중 5,000개를 무작위 추출한다.
Partial Class Forgetting: 무작위로 선정된 5개의 클래스에서 각각 20%의 데이터를 샘플링하여 총 5,000장의 Forget Set을 구성한다. 이는 데이터가 여러 클래스에 산재된 복합적인 상황을 모사한다.

6. 비교 알고리즘 구현 및 하이퍼파라미터

1) Fine-tuning (FT)

Forget Set을 배제하고 Retain Set 데이터로만 구성된 DataLoader를 사용하여 모델을 추가 학습한다.

파라미터: unlearn_epochs=100, unlearn_lr=0.01. 초기 학습률보다 낮은 학습률을 사용하여 모델의 급격한 파라미터 변화를 방지한다.

2) NegGrad (Negative Gradient)

Retain Set에 대해서는 일반적인 Cross-Entropy Loss 최소화를 수행하고, Forget Set에 대해서는 손실을 최대화하는 Gradient Ascent를 수행한다.

파라미터: alpha=0.9. 전체 손실 함수 L=α・L_retain -(1-α)・L_forget 에서 가중치를 조절하여 망각 강도를 제어한다.

3) SCRUB

교사-학생(Teacher-Student) 모델 구조를 사용한다. 원본 모델을 교사 모델로 고정(Freeze)하고, 복제된 학생 모델을 학습시킨다.

Retain Step: 학생 모델이 교사 모델의 출력 분포(Logits)를 모방하도록 KL Divergence Loss를 최소화한다 (Distillation).

Forget Step: 학생 모델이 교사 모델의 출력과 멀어지도록 KL Divergence를 최대화한다 (Unlearning).

파라미터: Maximization Steps=5, KL Penalty=1.0, Retain Weight=1.0, Temperature=4.0.

Ⅴ 실험 결과 및 분석

1. 실험 개요 및 평가지표

본 장에서는 제안하는 '기억 점수 기반 커리큘럼 언러닝 프레임워크'가 실제 모델의 망각 성능과 일반화 능력에 미치는 영향을 정량적으로 분석한다. 실험은 CIFAR-10 데이터셋과 ResNet-18 모델을 기반으로 수행되었으며, Class Forgetting, Random Forgetting, Random Class Forgetting의 세 가지 시나리오에서 검증되었다.

성능 평가는 다음 세 가지 지표(Metric)를 기준으로 수행된다.

Forget Accuracy (FA): 삭제 대상 데이터(Forget Set)에 대한 모델의 분류 정확도이다. 언러닝의 목표는 이 데이터를 잊는 것이므로, 수치가 낮을수록(이상적으로는 0% 또는 무작위 추측 수준) 우수하다.

Retain Accuracy (RA): 삭제되지 않은 잔여 데이터(Retain Set)에 대한 정확도이다. 원본 모델의 지식을 보존해야 하므로, 수치가 높을수록(재학습 모델 수준) 우수하다.

Test Accuracy (TA): 전체 테스트 데이터셋에 대한 정확도이다. 언러닝 과정에서 모델의 특징 추출기(Feature Extractor)가 붕괴되지 않고 일반화 성능을 유지하는지를 나타낸다.

알고리즘	커리큘럼 방향	Class Forgetting	Random Forgetting	Random Class Forgetting
Retrain	–	0.00 / 99.76 / 79.86	88.30 / 99.77 / 87.40	85.36 / 99.77 / 87.12
FT	Low-first	89.52 / 99.84 / 87.34	99.76 / 99.84 / 88.21	99.58 / 99.85 / 88.44
	High-first	80.38 / 98.81 / 84.92	99.80 / 99.90 / 87.03	98.44 / 98.92 / 86.32
	Random	94.40 / 99.89 / 87.89	98.82 / 98.85 / 86.24	99.70 / 99.91 / 87.10
Neggrad	Low-first	8.96 / 96.18 / 76.32	96.78 / 97.14 / 87.41	53.90 / 78.99 / 67.44
	High-first	8.54 / 87.45 / 70.33	96.92 / 97.23 / 87.02	54.42 / 79.35 / 66.98
	Random	8.76 / 89.58 / 71.96	96.98 / 97.25 / 87.23	54.64 / 78.16 / 67.12
SCRUB	Low-first	1.64 / 97.59 / 79.12	97.86 / 99.25 / 87.62	72.14 / 80.34 / 70.53
	High-first	1.64 / 93.66 / 78.12	97.86 / 98.15 / 86.24	70.58 / 72.60 / 68.34
	Random	1.56 / 97.75 / 79.48	97.90 / 99.25 / 86.87	70.08 / 76.12 / 69.45

[표 1] 알고리즘 및 커리큘럼 방향에 따른 언러닝 성능 비교 (Forget Accuracy / Retain Accuracy / Test Accuracy, %)

2. 시나리오별 심층 분석

1) Class Forgetting (특정 클래스 망각)

이 시나리오는 모델이 학습한 특정 클래스(개념) 전체를 지워야 하는 상황이다. Retrain 모델은 해당 클래스에 대해 0.00%의 정확도를 기록하여, 해당 개념이 완전히 제거되었음을 보여준다.

NegGrad의 성능 변화와 안정성: NegGrad 알고리즘에서 커리큘럼의 영향이 가장 뚜렷하게 나타났다.

High-first 전략의 부작용: 어려운 데이터를 먼저 처리했을 때, FA는 8.54%로 낮아져 망각에는 성공했으나, RA가 87.45%로 급락하였다. 이는 특정 개념을 지우는 과정에서 모델의 전체적인 특징 추출 능력이 손상되었음을 의미한다.

Low-first 전략의 효과: 반면 쉬운 데이터부터 처리한 경우, FA(8.96%)는 유사하게 유지하면서 RA를 96.18%까지 방어해냈다. 이는 High-first 대비 약 8.73%p 높은 수치로, 순차적 접근이 잔여 지식 보호에 효과적임을 입증한다.

FT 알고리즘과 High-first의 효율성: FT는 전반적으로 FA가 80~90%대로 높아 완전한 망각에는 한계를 보였다. 하지만 커리큘럼 간 비교에서는 High-first(FA 80.38%)가 Low-first(FA 89.52%)보다 약 9.14%p 더 낮은 FA를 기록하였다. 이는 잔여 데이터 학습을 통해 기존 기억을 덮어쓸 때는, 모델에 큰 영향을 주는 데이터부터 학습하는 것이 효율적임을 시사한다.

SCRUB의 견고함: SCRUB은 1%대의 FA를 기록하며 가장 우수한 망각 성능을 보였다. SCRUB 또한 Low-first 전략에서 RA가 97.59%로 High-first(93.66%)보다 높게 측정되어, NegGrad와 유사한 경향성을 보였다.

2) Random Class Forgetting (무작위 클래스 망각)

매 실험마다 무작위 클래스를 삭제하는 이 시나리오에서는 Class Forgetting보다 성능 변동성이 컸으나, 경향성은 유지되었다.

Low-first의 일반화 성능 유지: SCRUB의 경우, FA는 High-first(70.58%)가 Low-first(72.14%)보다 소폭 낮았으나, RA 측면에서는 Low-first(80.34%)가 High-first(72.60%)를 약 7.74%p 앞섰다. NegGrad 역시 Low-first가 가장 높은 RA(78.99%)와 TA(67.44%)를 기록하였다.

이는 여러 클래스를 지우는 복잡한 상황일수록 안정적인 커리큘럼(Low-first)이 모델의 일반화 성능(TA) 유지에 필수적임을 보여준다.

3) Random Forgetting (무작위 샘플 망각)

클래스 구분 없이 전체 데이터에서 무작위 샘플을 삭제하는 시나리오이다.
과소 망각(Under-forgetting) 현상: 모든 알고리즘에서 FA가 96%~99%대로 매우 높게 나타났다. 이는 삭제된 샘플들이 잔여 데이터와 동일한 클래스 분포를 가지기 때문이다. 모델은 개별 샘플을 잊더라도, 잔여 데이터를 통해 학습된 '클래스 공통 특징'을 통해 여전히 해당 샘플을 정답으로 분류해낸다. Retrain 모델의 FA가 88.30%인 점이 이를 뒷받침한다.
안정적인 보존 성능: 데이터 분포의 구조적 변화가 없으므로, 모든 알고리즘이 RA를 97%~99% 수준으로 완벽하게 유지하였다. 이 시나리오에서는 커리큘럼 간의 성능 격차는 미미하였다.

3. 알고리즘 메커니즘에 따른 최적 커리큘럼 분석

본 실험 결과는 언러닝 알고리즘의 작동 방식(Mechanism)에 따라 적합한 커리큘럼 전략이 달라짐을 보여준다. 이를 '손실 최대화 기반 기법'과 '지식 보존 기반 기법'으로 나누어 분석하였다.

1) 손실 최대화 기반 기법 (NegGrad, SCRUB) → Low-first 전략

NegGrad(Gradient Ascent)와 SCRUB(Discrepancy Maximization)은 삭제 대상에 대해 손실을 높여 모델이 해당 데이터를 '거부'하도록 학습한다.

메커니즘 분석: 기억 점수가 높은 '어려운 데이터'는 모델의 결정 경계(Decision Boundary)를 형성하는 핵심 샘플(Support Vector)일 가능성이 높다. High-first 전략을 사용하여 이러한 핵심 축을 초반부터 강하게 흔들면, 모델의 특징 공간(Feature Space) 전체가 왜곡되어 RA의 급격한 하락을 초래한다.

결론: 따라서 이러한 기법에는 Low-first 전략이 적합하다. 영향력이 적은 '쉬운 데이터'부터 점진적으로 지워나가며 모델이 파라미터 변화에 적응할 완충 시간을 제공해야, 망각 목표를 달성하면서도 모델의 붕괴를 막을 수 있다. (NegGrad 결과: Low-first가 High-first 대비 RA 약 9%p 보존)

2) 지식 보존 기반 기법 (Fine-tuning) → High-first 전략

Fine-tuning(FT)은 삭제 데이터를 직접 학습에 사용하지 않고, 잔여 데이터만을 재학습하여 기존 정보를 새로운 정보로 자연스럽게 '덮어쓰는(Overwriting)' 방식이다.

메커니즘 분석: 기억 점수가 낮은 '쉬운 잔여 데이터'는 모델이 이미 잘 알고 있는 데이터이므로, 이를 다시 학습해도 그래디언트(Gradient)가 작아 파라미터 변화가 거의 없다. 즉, Low-first 전략은 언러닝 초반에 망각 효과가 미미하다. 반면, High-first 전략은 모델에 큰 손실 값을 유발하는 '어려운 잔여 데이터'를 먼저 학습시킴으로써 큰 그래디언트를 발생시키고, 이를 통해 삭제 데이터가 차지하고 있던 파라미터 공간을 효과적으로 점유하게 만든다.

결론: FT와 같은 기법에는 High-first 전략을 적용하여 파라미터 업데이트를 촉진시키는 것이 망각 효율을 높이는 데 유리하다. (FT 결과: High-first가 Low-first 대비 FA 약 9%p 감소)

4. 망각과 보존의 트레이드오프 (Trade-off)

언러닝은 '삭제 데이터 망각(FA 감소)'과 '잔여 데이터 보존(RA 유지)'이라는 상충되는 목표를 동시에 달성해야 한다. 실험 결과, 적절한 커리큘럼의 도입이 이 두 지표 사이의 트레이드오프를 완화함을 확인하였다.

NegGrad의 안정성 개선: NegGrad는 강력한 망각(FA < 10%)을 제공하지만 RA 손실 위험이 크다. Low-first 커리큘럼은 High-first 대비 RA를 9%p 가까이 회복시키며, 망각 성능의 손실 없이 안정성을 확보하였다.

FT의 효율성 개선: FT는 완벽한 보존(RA > 99%)을 제공하지만 망각 성능이 떨어진다. High-first 커리큘럼은 RA를 훼손하지 않으면서 FA를 약 9%p 낮추어, FT의 약점인 '느린 망각'을 보완하였다.

결과적으로, "손실을 직접 조작하여 정보를 지우는 알고리즘(NegGrad, SCRUB)은 Low-first", "정보를 덮어쓰는 알고리즘(FT)은 High-first" 전략을 선택하는 것이 각 알고리즘의 약점을 보완하고 최적의 성능 균형을 달성하는 방법임을 실험적으로 입증하였다.

Ⅵ 한계점 및 향후 연구 방향

본 연구는 기억 점수 기반 커리큘럼 언러닝의 유효성을 실험적으로 입증하였으나, 다음과 같은 몇 가지 한계점을 지니고 있다. 본 장에서는 이러한 한계점들을 명확히 기술하고, 이를 극복하기 위한 향후 연구 방향을 제안한다.

1. 연구의 한계점

1) 기억 점수 산출의 연산 비용 및 근사 오차

본 연구의 핵심인 커리큘럼 구성을 위해서는 각 데이터 샘플의 망각 난이도(기억 점수)를 사전에 산출해야 한다. Feldman 등이 정의한 이론적으로 완벽한 기억 점수를 구하기 위해서는 수천 번 이상의 모델 재학습(Retraining)이 요구되므로, 현실적인 시간과 비용의 제약으로 인해 본 연구에서는 근사 지표(Proxy)를 사용하였다 . 그러나 이러한 근사 지표 역시 대규모 데이터셋(ImageNet 등)이나 거대 모델에 적용할 경우 상당한 연산 오버헤드(Computational Overhead)를 발생시킬 수 있다. 또한, 근사치와 실제 모델이 느끼는 난이도 간의 불일치(Discrepancy)가 발생할 경우, 최적의 커리큘럼 순서가 왜곡되어 언러닝 효율을 저하시킬 잠재적 위험이 존재한다.

2) 정적 커리큘럼(Static Curriculum)

본 연구에서 제안한 프레임워크는 언러닝 시작 전에 데이터 순서를 미리 결정(Pre-defined)하고, 고정된 순서대로 삭제를 진행하는 정적(Static) 방식을 채택하였다. 하지만 언러닝이 진행됨에 따라 모델의 파라미터 상태는 실시간으로 변화하며, 이에 따라 잔여 데이터와 삭제 데이터 간의 상대적인 중요도나 난이도 또한 동적으로 변할 수 있다. 현재의 정적 방식은 이러한 학습 도중의 변화를 반영하지 못하므로, 매 스텝(Step)마다 최적의 데이터를 선별하여 학습하는 이상적인 동적 스케줄링(Dynamic Scheduling)에 비해 최적화 효율이 떨어질 수 있다.

3) 실험 환경의 제한적 범위

제안된 기법의 유효성은 CIFAR-10 데이터셋과 ResNet-18 모델이라는 표준적인 벤치마크 환경에서 검증되었다. 그러나 최근 인공지능 분야의 주류가 되고 있는 트랜스포머(Transformer) 기반의 거대 언어 모델(LLM)이나 확산 모델(Diffusion Model) 등 생성형

AI 모델에 대해서는 추가적인 검증이 필요하다. 특히 생성 모델의 경우 '암기(Memorization)'의 정의가 분류 모델과 다르며, 데이터의 구조적 복잡성이 훨씬 높기 때문에 본 연구의 결과를 그대로 일반화하기에는 한계가 있다.

2. 향후 연구 방향

1) 적응형 커리큘럼 언러닝 (Adaptive Curriculum Unlearning)

정적 커리큘럼의 한계를 극복하기 위해, 언러닝 과정에서 모델의 상태를 실시간으로 모니터링하여 데이터 처리 순서를 유동적으로 변경하는 적응형 커리큘럼 연구가 필요하다. 예를 들어, 강화학습(Reinforcement Learning)이나 메타 러닝(Meta-learning) 기법을 도입하여, 현재 모델의 손실(Loss) 분포나 그래디언트(Gradient) 크기에 따라 다음 배치(Batch)에 포함될 데이터의 난이도를 스스로 결정하는 에이전트를 설계할 수 있다. 이를 통해 모델 붕괴 위험이 감지되면 즉시 쉬운 데이터를 주입하여 안정화하는 등 더욱 정교한 제어가 가능할 것이다.

2) 경량화된 난이도 측정 지표 개발

실용적인 언러닝 적용을 위해서는 기억 점수 산출에 소요되는 비용을 획기적으로 줄여야 한다. 따라서 재학습이나 복잡한 전처리 과정 없이, 데이터의 망각 난이도를 추정할 수 있는 경량화된 지표(Lightweight Metric) 개발이 시급하다. 모델의 불확실성(Uncertainty), 엔트로피(Entropy), 또는 영향 함수(Influence Function)의 1차 근사 등을 활용하여, 계산 비용은 낮으면서도 실제 난이도와 상관관계가 높은 새로운 지표를 탐색하는 연구가 요구된다.

3) 생성형 모델 및 다양한 도메인으로의 확장

이미지 분류를 넘어 다양한 도메인으로 커리큘럼 언러닝을 확장해야 한다. 거대 언어 모델(LLM): LLM에서 특정 지식(예: 개인정보, 유해 정보)을 삭제하거나 할루시네이션(Hallucination)을 교정할 때, 지식의 연관성에 따른 커리큘럼을 적용하여 언어 능력을 보존하면서 타겟 지식만 정밀하게 제거하는 연구.

멀티모달 모델: 텍스트와 이미지가 결합된 데이터에서 특정 양상(Modality)의 정보만 선택적으로 망각하는 복합적인 시나리오 연구.

4) 이론적 분석 및 최적화 경로 규명

경험적 실험 결과를 넘어, 데이터 처리 순서가 모델의 손실 지형(Loss Landscape) 내에서 최적화 경로에 구체적으로 어떤 영향을 미치는지에 대한 수학적·이론적 분석이 병행되어야 한다. 이를 통해 왜 특정 알고리즘에서는 특정 순서가 유리한지를 이론적으로 증명하고, 이를 바탕으로 일반화된 '언러닝 최적화 이론'을 정립하는 것이 궁극적인 연구 방향이 될 것이다.

참고문헌

[1] L. Bourtoule, V. Chandrasekaran, C. A. Choquette-Choo, H. Jia, A. Travers, B. Zhang, D. Lie, and N. Papernot, “Machine Unlearning,” 2021 IEEE Symposium on Security and Privacy (SP), 2021.

[2] A. Golatkar, A. Achille, and S. Soatto, “Eternal Sunshine of the Spotless Net: Selective Forgetting in Deep Networks,” Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 9304-9312, 2020.

[3] M. Kurmanji, P. Triantafillou, J. Hayes, and E. Triantafillou, “Towards Unbounded Machine Unlearning,” Advances in Neural Information Processing Systems (NeurIPS 2024), vol. 36, 2024.

[4] Y. Bengio, J. Louradour, R. Collobert, and J. Weston, “Curriculum Learning,” Proceedings of the 26th Annual International Conference on Machine Learning, pp. 41-48, 2009.

[5] K. Zhao, M. Kurmanji, G. O. Barbulescu, E. Triantafillou, and P. Triantafillou, “What Makes Unlearning Hard and What to Do About It,” 38th Conference on Neural Information Processing Systems (NeurIPS 2024), 2024.

[6] L. Yang, P. Ren, S. Wang, Z. Ren, Z. Chen, D. Yin, et al., “Curriculum Approximate Unlearning for Session-Based Recommendation,” arXiv preprint arXiv:2508.15263, 2025.

[7] V. Feldman, “Does Learning Require Memorization? A Short Tale About a Long Tail,” Proceedings of the 52nd Annual ACM SIGACT Symposium on Theory of Computing, pp. 954-959, 2020.